

Veri Madenciliği Teknikleri Kullanılarak Diyabetik Retinopati Teşhisi

Elif Beyza Emül
Dept. of Management Information
Systems, Başkent University
Ankara, Türkiye
beyzaemull@gmail.com

I. Özet—Diyabetik Retinopati, uzun süreli diyabet hastalarında, özellikle gelişmemiş ve gelişmekte olan ülkelerde, en sık görülen komplikasyondur. Diyabetik retinopatinin erken teşhisi, tedavinin zamanında yapılarak körlük riskini engellemesi açısından büyük önem taşımaktadır. Bilgisayar destekli yöntemler, diyabetik retinopatinin tespitini otomatikleştirerek erken teşhis sürecini hızlandırmaktadır. Bu çalışmanın amacı, Diabetic Retinopathy Debrecen veri seti üzerinde çeşitli veri madenciliği algoritmalarını uygulayarak diyabetik retinopatinin erken teşhisinde en etkili yöntemleri belirlemektir. Bu çalışma kapsamında yapılan literatür taramasında, diyabetik retinopati için uygulanan çeşitli sınıflandırma algoritmalarının farklı çalışmalarda gösterdiği sonuçlar incelenmiştir. Bulgular bölümünde, mevcut veri setine WEKA uygulaması aracılığıyla Lojistik Regresyon, Naïve Bayes, Decision Tree, k-NN, Yapay Sinir Ağları (ANN) sınıflandırma algoritmaları uygulanmıştır ve sonuçlar karşılaştırılmıştır. Sonuçlar ve öneriler bölümünde, yapılan karşılaştırma sonucu en etkili sınıflandırma algoritmasının %74.89 doğruluk oranıyla Lojistik Regresyon olduğu belirtilmiştir ve mevcut çalışmayla ilgili kurum ve kuruluşlar ilişkilendirilmiştir.

Anahtar Kelimeler—diyabet, diyabetik retinopati, veri madenciliği, sınıflandırma

II. GİRİŞ

Diyabet, pankreasın yeterli insülin üretme veya salgılama yeteneğinin olmaması veya yetersizliği nedeniyle kan şekeri seviyelerinin artma eğiliminde olduğu kronik bir hastalıktır[2]. Diyabetik retinopati (DR), uzun süreli diyabet rahatsızlığı olan hastalarda en sık görülen komplikasyondur ve bu durum nihayetinde körlüğe yol açar[1]. Diyabetik Retinopatinin erken teşhisi, hastanın görme yetisini etkili bir şekilde sürdürebilmesi için çok önemlidir[2].

Manuel yöntemin aksine, bilgisayar destekli karar destek araçları diyabetik retinopatiyi hassas bir şekilde tespit eder. Diyabetik retinopati vakalarının neredeyse %75'i, yeterli ekipman veya tespit araçlarına sahip olmayan yoksul ülkelerden gelmektedir [3]. Bu nedenle, diyabetik retinopatiyi tespit etmeye yönelik karar destek sistemleri, diyabetik retinopatinin erken teşhisinde etkilidir [4].

Veri madenciliği, büyük bir bilgi veri tabanından ham bilgileri analiz etme ve anlamlı kalıpların ve veri eğilimlerinin ortaya çıktığı yararlı bilgilere dönüştürme sürecidir. Günümüzde sağlık sektörü, hastalar, klinik semptomlar, hastalık tespit teknikleri vb. hakkında bol miktarda veri üretmektedir. Veri madenciliği, sağlık hizmetlerinin çeşitli alanlarında potansiyel olarak yararlı olmuştur[1]. Diyabetik retinopatinin erken teşhisinin önemi nedeniyle, bu konuda süreci hızlandırmak adına yapılan veri madenciliği çalışmaları da büyük önem taşımaktadır. Bu çalışmada da Messidor görüntü setinden çıkarılan özellikleri içeren Diabetic Retinopathy Debrecen veri seti incelenmiş, WEKA

uygulanması üzerinden mevcut veri setine çeşitli sınıflandırma algoritmaları uygulanarak en etkili sınıflandırma yönteminin belirlenmesi hedeflenmiştir.

Diabetic Retinopathy Debrecen veri seti, bir görüntünün diyabetik retinopati belirtileri içerip içermediğini tahmin etmek için Messidor görüntü setinden çıkarılan özellikleri içermektedir. Tüm özellikler ya tespit edilen bir lezyonu, anatomik bir parçanın tanımlayıcı bir özelliğini ya da görüntü düzeyinde bir tanımlayıcıyı temsil etmektedir[5]. Bu veri seti, biri hedef değişken olmak üzere, tam sayı ve gerçek sayı türünde 20 özellik içeren 1151 örnekten oluşmaktadır. Diyabetik retinopatiyi temsil eden bu 20 özellik Tablo 1'de sırasıyla açıklanmıştır.

Tablo 1 : Veri kümesindeki özellikler ve açıklamaları [1]

Özellik	Tip	Tanımlama
0.	İkili	Kalite değerlendirmesinin ikili sonucu 0: Kötü 1: Yeterli kalite
1.	İkili	Ön taramanın ikili sonucu 0: Retina anormalliğinin olmaması 1: Retina anormalliğinin olması
2-7.	Tam Sayı	MA1 – MA6, mikroanevrizma tespitinin sonuçlarını içerir. Her özellik değeri değişen güven seviyelerinde (alfa= 0.5 ile 1) bulunan mikroanevrizma sayısını temsil eder.
8-15.	Sürekli	Eksüdatlar (Eksüdat1 – Eksüdat8), mikroanevrizmalarla aynı bilgileri içerir. Ancak mikroanevrizmanın aksine lezyonları oluşturan piksel sayısı yerine bir dizi nokta ile temsil edilirler. Bu sebeple oluşan farklı görüntü boyutlarını telafi etmek için ise bu özellikler, lezyon sayısının ROI çapına bölünmesiyle normalize edilir.
16.	Sürekli	Makulanın merkezi ile optik diskin merkezi arasındaki Öklid mesafesi
17.	Sürekli	Optik diskin çapı
18.	İkili	AM/FM sınıflandırmasının ikili sonucu

19.	İkili	Sınıf etiketi, hedef değişken, 0: Diyabetik retinopati belirtisinin olmaması 1: Diyabetik retinopati belirtisinin olması
-----	-------	--

Bu bölümde incelenen konu genel hatlarıyla açıklanmış, ilgili veri seti ve veri setinin özellikleri tanımlanmıştır. Bu makalenin geri kalanı şu şekilde düzenlenmiştir:

Bölüm III'te makalenin geliştirilmesinde kullanılan teorik yaklaşımlar ve kavramlar açıklanmıştır. Ele alınan konuyla ilgili en az 5 makale incelenerek literatür taraması yapılmış geçmiş çalışmaların analizi ve bu çalışmaların konuya nasıl ışık tuttuğu açıklanmıştır.

Bölüm IV'te incelenen veri seti WEKA uygulamasına yüklenmiş, bu uygulamada çeşitli sınıflandırma algoritmaları uygulanarak elde edilen bulgular paylaşılmıştır. Bulgular, literatür veya araştırmalardan elde edilen kanıtlarla desteklenmiş ve Bölüm III'teki ilgili teorilerle karşılaştırılmıştır.

Bölüm V'te ise elde edilen bulgulardan çıkarılabilecek sonuçlar paylaşılmıştır. İncelenen konu uygun görüldüğü işletmeler, hükümetler ve sivil toplum kuruluşlarıyla ilişkilendirilmiş, birtakım önerilerde bulunulmuştur.


III. LİTERATÜR TARAMASI

Bu makale geliştirilirken yapılan literatür taramasında veri madenciliği, makine öğrenimi ve derin öğrenme alanlarına ait teorik yaklaşımlar ve kavramlar ele alınmıştır.

Diyabetik retinopati sınıflandırmasına ilişkin ilk çalışmalar, esas olarak retina görüntülerinin özelliklerinin elle mühendislik yöntemleriyle çıkarılmasına ve makine öğrenme yöntemleriyle sınıflandırılmasına dayanmaktadır. Literatürde bazı çalışmalar diyabetik retinopatiyi eksüdatlar, mikroanevrizmalar vb. lezyonları tespit ederek sınıflandırmaktadır. Diyabetik retinopati belirtilerinin tanımlanması veya diyabetik retinopati görüntülerinden bazı sayısal indekslerin hesaplanması sırasında çoğunlukla Decision Trees, Naive Bayes, K-NN ve Support vector machines (SVMs) algoritmalarının kullanıldığı görülmüştür [6].

R. Priya ve P.Aruna [7], toplamda 350 fundus görüntüsünün 100'ünü eğitim için, 250'sini ise test için kullanmışlardır. Görüntüler normal görüntü, Nonproliferatif Diyabetik Retinopati (NPDR) ve Proliferatif Diyabetik Retinopati (PDR) olmak üzere üç gruba ayrılmıştır. Diyabetik retinopatiyi teşhis etmek için olasılıksal sinir ağı (PNN), Bayes sınıflandırması ve destek vektör makinesi (SVM) gibi üç model açıklanmış ve performansları karşılaştırılmıştır. Deney sonuçları, PNN'nin %89,6 doğruluk oranına, Bayes Sınıflandırıcısının %94,4 doğruluk oranına ve SVM'nin %97,6 doğruluk oranına sahip olduğunu göstermektedir. Bu, SVM modelinin diğer tüm modellerden daha iyi performans gösterdiği anlamına gelir.

SVM'ler hiper düzlem sınıfına dayanmaktadır. Şekil 1'de en iyi genelleme performansını garanti eden hiper düzlemin, iki sınıf arasındaki maksimum ayırım marjına sahip olan hiper düzlem olduğu gösterilmiştir.



Şekil1: İki boyutlu eğitim seti için ayırıcı hiper düzlem (w, b)

$$K(x, x') = (x \cdot x' + 1)^d$$

Burada x ve x' üç sınıf için özellik vektörleridir, d ise çekirdek parametresidir. Her bir retina görüntüsü boyutu 250 * 6'dır. Çıktı, normal, NPDR ve PDR olmak üzere üç sınıftan biri olabilir.

PNN mimarisi birbirine bağlı birçok işlem biriminden veya nörondan oluşur ve ardışık katmanlarda (Pattern, Toplama, Çıkış) organize edilir. Kullanılan aktivasyon fonksiyonu Gaussian çekirdeğidir. Toplama katmanında nöron sayısı kategori sayısına eşittir. Çıkış katmanında her desen sınıflandırması için bir düğüm bulunur. Her gizli düğümün toplamı çıkış katmanına gönderilir ve en yüksek değer kazanır. Bu yöntem, normal, NPDR ve PDR olmak üzere üç sınıf için uygulanmıştır.

Bayes sınıflandırıcı, ayırıcı fonksiyonları analiz eden geleneksel, istatistik tabanlı bir sınıflandırıcıdır.

$$P(w_j|x) = \frac{P(x|w_j)P(w_j)}{P(x)}$$

- x, göz görüntülerinin [250 * 6] boyutlarındaki özellik değeridir.
- P(w_j/x), verilen özellikler için (Yarıçap, Çap, Alan, Yay Uzunluğu, Merkez Açısı ve Yarı Alan) NPDR, PDR gibi hastalık ve normal olma olasılığıdır.
- P(x), özellik değerlerinin olasılığıdır.

S. Vadloori, Y.-P. Huang, W.-C Wu [1], çalışmalarında, veri setinden toplam 983 örnek analiz etmişlerdir. Bu veri seti diyabetik retinopati tanısı konmuş hastaların %51,3'ünü, geri kalan %48,7'si diyabetik retinopati tanısı konmamış hastalardan oluşmaktadır. Daha yüksek varyansa sahip özelliklerin değerli bilgiler içerdiği öne sürülmüştür.


K-NN sınıflandırmasında veri kümesinden sınıf etiketini tahmin etmek için 10 katlı çapraz doğrulama ile birlikte Öklid mesafesi bir kriter olarak kullanılmış %71,25 doğruluk elde edilmiştir.

Random Forest sınıflandırma modelinde MA'ların ve EXU'ların diyabetik retinopatiyi tespit etmede iki kritik öznelik olduğunu gözlemlenmiştir. MA'lar arasında MA0.5 kritik bir öznelik olarak görülürken EXU'lar arasında EXU7 kritik olarak gözlemlenmiştir. Bu sınıflandırma modelinde, eğitim setinde %72,71 ve tahmin setinde %71,76 doğruluk elde edilmiştir.

Regression tree sınıflandırma modelinde kararlar, kök düğümden yaprak düğüme doğru izlenerek tahmin edilir, yanıt yaprak düğümden bulunur. Diyabetik retinopati oluşma olasılığıyla ilgili kritik özneliğe sahip kuralları oluşturur. Örneğin, EXU7 özelliği incelendiğinde $EXU7 \leq 0,01029$ olduğunda vakaların %80'inin DR içermediğini ve $EXU7 \geq 0,136501$ olduğunda vakaların %10'unun DR içerdiğini göstermektedir.

Naive Bayes sınıflandırma modelinde 10 katlı çapraz doğrulama kullanılmıştır. Mevcut çalışmada 590 vaka eğitim veri seti olarak kabul edilmiş ve geri kalan vakalar test veri seti olarak alınmıştır.

Naive Bayes yöntemi, diyabetik retinopati oluşumunu belirlemede eğitim setinde %83,56 doğruluk ve tahmin setinde %80,15 doğruluk göstermiştir. Ayrıca AUC değeri 0,816 (Şekil 2) olarak görülmüştür, bu da sınıflandırma yönteminin diyabetik retinopati varlığını tespit etmekte iyi bir performans sergilediğini göstermektedir.



Şekil2: Naive Bayes modeli için ROC eğrisi

İncelenen sınıflandırma modelleri arasında en iyi performansı Naive Bayes yönteminin gösterdiğini belirtmişlerdir.

O.F. Gurcan , O.F. Beyca ve O. Dogan[6], çalışmalarında Messidor-2 veri setini kullanmışlardır. Messidor-2 veri seti 1.748 görüntü içermektedir ve değerlendirilen dereceler şunlardır: Diyabetik retinopati yok, hafif, orta, şiddetli ve proliferatif diyabetik retinopati. NRDR sınıfı diyabetik retinopati olmayan ve hafif vakaları dikkate alır. RDR sınıfı ise orta (veya daha kötü) vakaları dikkate alır.

Doğrusal SVC için, maksimum yineleme sayısı 1.000 ile 11.000 arasında aranmıştır. SVC için olasılık parametresi, sınıflandırıcının olasılık tahminleri yapmasını sağlayan "Doğru" olarak seçilmiş, çekirdek parametreleri (doğrusal, poli, rbf, sigmoid) ve derece (3 ile 10 arasında) test edilmiştir. Maksimum doğruluğun (%89,11), parametre kombinasyonu olasılık = Doğru, çekirdek = poli, derece = 8 olduğunda elde edildiği belirtilmiştir.

Lojistik regresyon sisteminde iterasyon sayısı 100 ile 1200 arasında test edilirken mevcut çözücü parametreleri (newton-cg; lbfgs, liblinear, sag, saga) de karşılaştırılmıştır. Lbfgs çözücüsünün maksimum doğruluk sağladığı belirtilmiştir. Lojistik regresyonun performansı SVC'ye yakındır.

M. Çerkezi [8], çalışmada K-en Yakın Komşu, Ağırlıklı Oylama KNN ve Naive Bayes sınıflandırma

yöntemlerini kullanmıştır. Uygulamada çapraz geçerlilik yöntemini kullanarak $k = 7$ doğruluk oranında en iyi sonuç alınmıştır.

Veri madenciliği sınıflandırma yöntemlerinin test sonuçlarını elde etmek ve değerlendirmek için, 10-katlamalı çapraz doğrulama yöntemi kullanılmıştır.

Tablo2: Sınıflandırıcıların teşhis sonuçları [8]

Doğruluk oranı (%)			
	K-en yakın komşu	Ağırlıklı oylama KNN	Naive Bayes
Öklid mesafesi	92.28	92.48	88.89
Manhattan mesafesi	92.19	92.79	
Minkowski mesafesi	91.65	91.71	

K-en yakın komşu ve ağırlıklı oylama KNN yöntemleri %90 değerini aşarak en iyi doğruluk oranı vermiş olup, bunun yanında Naive Bayes sınıflandırıcısı %88 doğruluk oranı göstermektedir. Mesafe ölçümlerinde ise Öklid ve Manhattan ölçümleri test sonuçlarında en başarılı olarak gözlenmişlerdir.

Z. Khairudin, N.A.A. Razak, H.A.A. Rahman, N. Kamarudin ve N.A.B.A. Aziz[9] , çalışmalarında Lojistik Regresyon, Decision Tree ve Yapay Sinir Ağı (ANN) modellerini kullanmışlardır. Çalışmalarında kullanılan veri seti Ocak 2014 ile Aralık 2018 tarihleri arasında UİTM Tıp Uzmanlık Merkezi Göz Hastalıkları Kliniği'nden seçilen 361 Tip II diyabet hastasından ve 17 değişkenden oluşmaktadır.

Lojistik Regresyon modelinde Enter, Stepwise Forward, Backward yöntemlerinin performansları karşılaştırılmıştır (Tablo3). Forward yöntemi, diğer seçim yöntemlerine kıyasla doğrulama veri setinde en yüksek duyarlılık (%50,0), özgüllük (%79,03) ve doğruluk oranına (%66,36) sahip olduğu için en iyi model olarak seçilmiştir.

Tablo3: Model Performansının Karşılaştırılması (Lojistik Regresyon) [9]

Model	Sensitivity	Specificity	Accuracy Rate	ROC Index	Significant Variables
Enter	Training: 70.64	80.99	76.49	0.833	Duration of DM, Nephropathy, Neuropathy and HbA1C
	Validation: 50	74.19	63.64	0.644	
Stepwise	Training: 66.97	81.69	75.3	0.819	Duration of DM, Diastolic BP, Nephropathy, Neuropathy, Diabetic Foot and HbA1C
	Validation: 47.92	74.19	62.73	0.693	
Forward	Training: 65.14	80.28	73.71	0.816	Duration of DM, Nephropathy, Neuropathy, Diabetic Foot and HbA1C
	Validation: 50	79.03	66.36	0.709	
Backward	Training: 61.47	80.28	72.11	0.812	Duration of DM, Nephropathy, Neuropathy, Diabetic Foot and HbA1C
	Validation: 47.92	77.42	64.55	0.717	

Decision Tree modelinde, Gini, Entropy ve Ki-Kare yöntemleri karşılaştırıldığında (Tablo4) Gini İndeksi, en yüksek özgüllük (%70,97) ve doğruluk (%64,55) oranına ve en düşük yanlış sınıflandırma oranına (0,3546) sahip olduğu için en iyi model olarak seçilmiştir.

Tablo4: Model Performansının Karşılaştırılması
(Decision Tree) [9]

Model		Sensitivity	Specificity	Accuracy Rate	ROC Index	Significant Variables
Gini	Training	70.64	83.8	78.09	0.832	Age, BMI, Duration of DM, Systolic of BP, Nephropathy and HbA1C
	Validation	56.25	70.97	64.55	0.635	
Entropy	Training	66.06	85.21	76.89	0.814	Age, Duration of DM, Systolic of BP, Nephropathy and HbA1C
	Validation	54.17	70.97	63.64	0.671	
Chi-Square	Training	88.07	54.23	68.92	0.711	Duration of DM
	Validation	72.92	51.61	60.91	0.623	

ANN modelinde, doğrulama veri seti %64.55 doğruluk oranı gösterirken eğitim veri seti %86.85 doğruluk oranı göstermiştir. Buna göre eğitim veri setinin doğruluk veri setine kıyasla daha iyi performans gösterdiği görülmektedir (Tablo5). Eğitim setinde duyarlılık oranı %86,24, özgülük %87,32 ve doğruluk oranı %86,85'tir. ANN modeli için tahmin performansı analizinden, diyabetik retinopati örneklerine sahip hastaların %56,25'i doğru bir şekilde diyabetik retinopatiye sahip olarak sınıflandırılırken, diyabetik retinopati örneklerine sahip olmayan hastaların %70,97'si doğru bir şekilde diyabetik retinopatiye sahip olmadığı şeklinde sınıflandırılmıştır. Doğrulama veri seti ise %64.55 a

Tablo5: Model Performansının Karşılaştırılması
(ANN)[9]

Model		Sensitivity	Specificity	Accuracy Rate	ROC Index	Significant Variables
Artificial Neural Network (ANN)	Training	86.24	87.32	86.85	0.919	Duration of DM, Nephropathy, Neuropathy, Diabetic Foot and HbA1C
	Validation	56.25	70.97	64.55	0.667	

Diyabetik retinopatinin tahmininde en iyi seçilen model, diğer tahmin modellerine göre en yüksek duyarlılık, özgülük ve doğruluk oranına sahip olduğu için Forward yöntemini kullanan Lojistik Regresyon olmuştur. Decision Tree modeli Gini yöntemiyle ikinci sırada ve ANN modeli üçüncü sırada yer almıştır.

IV. BULGULAR

Bu bölümde Diabetic Retinopathy Debrecen veri setine, WEKA uygulaması aracılığıyla Lojistik Regresyon, Naïve Bayes, Decision Tree, k-NN, Yapay Sinir Ağları (ANN) sınıflandırma algoritmaları 10 - katlamalı çapraz geçerlilik yöntemi (10 – fold cross validation) ile uygulanmıştır. Elde edilen bulgular, Bölüm III'te incelenen literatür çalışmalarıyla karşılaştırılarak yorumlanmış, hangi yöntemin diyabetik retinopatinin teşhisinde en doğru sonucu verdiği analiz edilmiştir.

A. Logistic Regression

Lojistik regresyon, makine öğreniminde en çok kullanılan ikili sınıflandırma algoritmalarından biridir. Lojistik regresyon doğrusal bir sınıflandırma modelidir, herhangi bir gerçek değerli sayıyı alır ve 0 ile 1 arasında bir değere dönüştürür[6].

Kullandığımız veri setinde diyabetik retinopati olanlar ve olmayanlar şeklinde ayrılmış 2 sınıf bulunmaktadır. Tablo6, her bir özelliğin Class 0 (Diyabetik Retinopati olmama durumu) için göstermiş olduğu katsayıları gösterir.

Tablo6: WEKA Lojistik Regresyon Sınıflandırması Uygulamasında Özelliklerin Katsayıları

Variable	Class 0
0	-18.8828
1	0.9939
2	-0.9003
3	0.4125
4	0.3238
5	0.1777
6	0.0399
7	-0.0543
8	-0.0092
9	0.0181
10	-0.0057
11	0.1583
12	-0.3298
13	1.7724
14	-7.9445
15	-0.7173
16	0.6334
17	7.4921
18	0.2828
Intercept	17.9885

Tablo6 incelendiğinde kalite özelliğinin (0.) -18.8828 değeriyle en düşük katsayıya sahip olduğu görülür. Buna göre görüntü kalitesi yeterli olduğunda (kalite = 1) Class 0 (diyabetik retinopati olmama) olasılığı azalırken, Class 1 (diyabetik retinopati olma) olasılığının arttığı söylenebilir. Optik diskin çapı özelliği (17.) ise 7.4921 değeriyle yüksek pozitif kat sayıya sahiptir. Buna göre optik diskin çapındaki artışın Class 0 olasılığını yüksek ölçüde arttırdığı söylenebilir.

Tablo7: WEKA Lojistik Regresyon Sınıflandırması Uygulamasında Özelliklerin Odds Ratios Değerleri

Variable	Odds Ratios...
0	0
1	2.7018
2	0.4065
3	1.5107
4	1.3824
5	1.1945
6	1.0407
7	0.9472
8	0.9909
9	1.0182
10	0.9943
11	1.1716
12	0.719
13	5.8852
14	0.0004
15	0.4881
16	1.8839
17	1793.8947
18	1.3269

Tablo7 incelendiğinde eksüdat6 özelliğinin (13.) odds ratios değeri 5.8852 olarak görülür. Bu durumun Class 0 (diyabetik retinopati yok) olasılığını ciddi ölçüde desteklediği ve eksüdat6 özelliğindeki birimlik artışın Class 0 olasılığını yaklaşık 6 kat arttırdığı söylenebilir.

Tablo8: WEKA Lojistik Regresyon Sınıflandırması Uygulaması Sonuç

```

=== Summary ===

Correctly Classified Instances      862           74.8914 %
Kappa statistic                    0.5002
Mean absolute error                 0.3236
Root mean squared error             0.4061
Relative absolute error             64.9699 %
Root relative squared error         81.3749 %
Total Number of Instances          1151

=== Detailed Accuracy By Class ===

          TP Rate  FP Rate  Precision  Recall  F-Measure  MCC      ROC Area  PRC Area  Class
0.806    0.301    0.703    0.806    0.751    0.505    0.831    0.779    0
0.699    0.194    0.803    0.699    0.747    0.505    0.831    0.871    1
Weighted Avg.    0.749    0.245    0.756    0.749    0.749    0.505    0.831    0.828

=== Confusion Matrix ===
      a  b  <-- classified as
435 105 |  a = 0
184 427 |  b = 1

```

Lojistik Regresyon yöntemi, 1151 örneğin 862 tanesini doğru sınıflandırarak %74.89 oranında başarı göstermiştir. Karışıklık matrisinde, 435 kişinin diyabetik retinopati olmadığı doğru şekilde tespit edilmiş, 427 kişinin diyabetik retinopati olduğu doğru şekilde tespit edilmiş ve teşhis konmuştur. Ancak 184 kişiye diyabetik retinopatiye konmadığı yönünde, 105 kişiye de diyabetik retinopati değilken diyabetik retinopati olduğu yönünde yanlış teşhis konmuştur.

O.F. Gurcan , O.F. Beyca ve O. Dogan[6], çalışmalarında lojistik regresyonun SVC’ye benzer bir doğruluk oranı (%89.11) gösterdiğini belirtmişlerdi. Bu çalışmadan elde edilen sonuçlar da lojistik regresyon yönteminin diyabetik retinopati teşhisinde etkili bir sınıflandırma algoritması olduğunu göstererek O.F. Gurcan , O.F. Beyca ve O. Dogan[6] çalışmalarını desteklemektedir.

B. Naïve Bayes

Naive Bayes, hedef değişkenle bağımsız değişkenler arasındaki ilişkiyi analiz eden tahminci ve tanımlayıcı bir sınıflama algoritmasıdır[8].

Bu çalışmada kullandığımız veri setine Naïve Bayes algoritması uygulandığında özellikler (Tablo9) ve genel performans özeti (Tablo10) incelenmiştir.

Tablo9: WEKA Naïve Bayes Sınıflandırması Uygulamasında Özelliklerin Değerleri

Attribute	Class	0	1	6	mean	std. dev.	weight sum	precision	std. dev.	0.5562	3.3326
		(0.47)	(0.53)		25.4179	31.7249			540	611	
					std. dev.	18.289	20.0319		0.0648	0.0648	
					weight sum	540	611				
0	mean	0.9926	1	precision	1.1566	1.1566	13	mean	0.0413	0.3623	
	std. dev.	0.1667	0.1667					std. dev.	0.157	1.4264	
	weight sum	540	611					weight sum	540	611	
	precision	1	1					precision	0.0348	0.0348	
1	mean	0.9407	0.8985	7	mean	19.1338	22.9341	14	mean	0.0066	0.1546
	std. dev.	0.2361	0.302		std. dev.	14.2687	15.618		std. dev.	0.0349	0.537
	weight sum	540	611		weight sum	540	611		weight sum	540	611
	precision	1	1		precision	1.2941	1.2941		precision	0.0143	0.0143
2	mean	30.474	45.5367	8	mean	60.4841	67.2771	15	mean	0.0032	0.0669
	std. dev.	20.7362	27.3944		std. dev.	50.719	64.3686		std. dev.	0.0159	0.2414
	weight sum	540	611		weight sum	540	611		weight sum	540	611
	precision	1.3761	1.3761		precision	0.354	0.354		precision	0.0088	0.0088
3	mean	30.1404	42.9575	9	mean	23.074	23.1	16	mean	0.523	0.5234
	std. dev.	20.4472	25.414		std. dev.	19.7019	23.1387		std. dev.	0.0285	0.0276
	weight sum	540	611		weight sum	540	611		weight sum	540	611
	precision	1.2718	1.2718		precision	0.1466	0.1466		precision	0.0002	0.0002
4	mean	29.4532	40.1807	10	mean	8.2346	9.1221	17	mean	0.109	0.1079
	std. dev.	20.1926	23.7814		std. dev.	10.5544	12.3712		std. dev.	0.0175	0.0183
	weight sum	540	611		weight sum	540	611		weight sum	540	611
	precision	1.2143	1.2143		precision	0.094	0.094		precision	0.0001	0.0001
5	mean	27.8788	36.2326	11	mean	1.4003	2.2213	18	mean	0.3974	0.3175
	std. dev.	19.2999	21.8292		std. dev.	2.7919	4.6671		std. dev.	0.4792	0.4655
					weight sum	540	611		weight sum	540	611
					precision	0.058	0.058		precision	1	1

Tablo9 incelendiğinde kalite (0.) özelliğinin Class 0 ve Class 1 için mean değerlerinin sırasıyla 0.9926 ve 1 olduğu görülmektedir. Mean değerlerinin birbirine yakın olması, kalite özelliğinin Naïve Bayes algoritması için ayırt edici bir özellik olmadığını göstermektedir. Buna karşın MA1 özelliği

(2.) incelendiğinde Class 0 ve Class 1 için mean değerlerinin sırasıyla 30.474 ve 45.5367 olduğu görülmektedir. Mean değerlerinin aralarındaki fark yüksek olduğundan bu özelliğin Naïve Bayes algoritması için ayırt edici bir özellik olduğu söylenebilir.

Tablo10: WEKA Naïve Bayes Sınıflandırması Uygulaması Sonuç

```

Time taken to build model: 0.01 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      654           56.8202 %
Kappa statistic                    0.1729
Mean absolute error                 0.4326
Root mean squared error             0.6507
Relative absolute error             86.8494 %
Root relative squared error         130.387 %
Total Number of Instances          1151

=== Detailed Accuracy By Class ===

          TP Rate  FP Rate  Precision  Recall  F-Measure  MCC      ROC Area  PRC Area  Class
0.954    0.773    0.522    0.954    0.675    0.259    0.682    0.596    0
0.227    0.046    0.848    0.227    0.359    0.259    0.682    0.724    1
Weighted Avg.    0.568    0.387    0.695    0.568    0.507    0.259    0.682    0.664

=== Confusion Matrix ===
      a  b  <-- classified as
515  25 |  a = 0
472 139 |  b = 1

```

Tablo10 incelendiğinde, Naïve Bayes algoritmasının mevcut veri setindeki 1151 örnekten 654 tanesini doğru sınıflandırarak %56.8202 oranında başarı yakaladığı görülmektedir. Karışıklık matrisinde, 515 kişinin diyabetik retinopati olmadığı doğru şekilde tespit edilmiş, 139 kişinin diyabetik retinopati olduğu doğru şekilde tespit edilmiş ve teşhis konmuştur. Ancak 472 kişiye diyabetik retinopatiye konmadığı yönünde, 25 kişiye de diyabetik retinopati değilken diyabetik retinopati olduğu yönünde yanlış teşhis konmuştur. Yanlış teşhis sayısının fazla olması sebebiyle Naïve Bayes algoritmasının başarı oranı düşmüştür.

S. Vadloori, Y.-P. Huang, W.-C Wu [1], çalışmalarında Naïve Bayes algoritmasının, diyabetik retinopati oluşumunu belirlemede %80,15 doğruluk gösterdiğini belirtmişlerdi ancak bu çalışmada kullanılan Diabetic Retinopathy Debrecen veri setinde Naive Bayes algoritmasının yeterince etkili olmadığı söylenebilir.

C. Decision Tree

Bir karar ağacı (DT), düğümlerden, dallardan ve dallardan oluşan hiyerarşik bir modeldir. Karar ağaçları, çeşitli senaryolara bağlı olarak veri kümelerini bölmenin yollarını belirleyen bir mantık aracılığıyla oluşturulur. Ağacı oluşturma sürecinde her aşamada hangi özelliğin bölüneceğini seçmek için bilgi kazancı kullanılır[10].

Bu çalışmada kullandığımız veri setine Decision Tree algoritması uygulandığında özellikler (Tablo11) ve genel performans özeti (Tablo12) incelenmiştir.

Tablo11: WEKA Decision Tree Sınıflandırması Uygulamasında Özelliklerin Değerleri

```

14 <= 0.02029
| 2 <= 55
| | 1 <= 0
| | | 7 <= 1: 0 (4.0)
| | | 7 > 1
| | | | 8 <= 101.64826
| | | | 14 <= 0.001954
| | | | 8 <= 61.995063
| | | | 11 <= 0.186842
| | | | 11 <= 0.955217
| | | | 18 <= 0
| | | | 3 <= 29: 1 (10.0/1.0)
| | | | 3 > 29
| | | | 2 <= 41: 0 (4.0)
| | | | 2 > 41: 1 (4.0/1.0)
| | | | 18 > 0
| | | | 8 <= 8.030835: 0 (2.0)
| | | | 8 > 8.030835: 1 (2.0)
| | | | 11 > 0.955217: 0 (4.0/1.0)
| | | | 11 > 0.186842: 1 (14.0)
| | | | 8 > 61.995063: 0 (8.0/1.0)
| | | | 14 > 0.001954: 0 (3.0)
| | | | 8 > 101.64826: 1 (10.0)
| | 1 > 0
| | | 2 <= 17
| | | | 6 <= 13
| | | | 2 <= 7
| | | | 12 <= 0.001053: 0 (34.0/3.0)
| | | | 12 > 0.001053
| | | | 9 <= 9.113819: 1 (8.0/1.0)
| | | | 9 > 9.113819
| | | | 8 <= 232.191751: 0 (27.0/2.0)
| | | | 8 > 232.191751: 1 (3.0/1.0)
| | | 2 > 7
| | | | 5 <= 6: 1 (10.0)
| | | | 5 > 6
| | | | 2 <= 11
| | | | 5 <= 8
| | | | 18 <= 0

```

Tablo11 incelendiğinde “|” işaretinin düğümden ayrılan yeni bir koşul belirttiği görülür. “<=”, “>” işaretleri karar koşuludur. Bazı satırların sonlarında “: 0 veya : 1” ifadeleri görülmektedir, bu izlenilen koşullar sonucunda verilen karardır. Örneğin; 3 <= 29: 1 (10.0/1.0) ifadesi, MA2 (3.) özelliğinin 29’ dan küçük veya eşit olma koşulunu sağlayan 10 örnek olduğunu ancak 1 tanesinin yanlış sınıflandığını göstermektedir.

Tablo12: WEKA Decision Tree Sınıflandırması Uygulaması Sonuç

```

=== Summary ===

Correctly Classified Instances      741          64.3788 %
Kappa statistic                    0.2897
Mean absolute error                 0.3796
Root mean squared error            0.5125
Relative absolute error             76.2052 %
Root relative squared error        102.6913 %
Total Number of Instances         1151

=== Detailed Accuracy By Class ===

      TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
    0,680    0,388    0,608    0,680    0,642    0,292    0,685    0,614    0
    0,612    0,320    0,684    0,612    0,646    0,292    0,685    0,694    1
Weighted Avg.    0,644    0,352    0,648    0,644    0,644    0,292    0,685    0,656

=== Confusion Matrix ===

      a  b  <-- classified as
    367 173 |  a = 0
    237 374 |  b = 1

```

Tablo12 incelendiğinde Decision Tree algoritmasının veri setindeki 1151 örnekten 741 tanesini doğru sınıflandırarak %64.3788 oranında başarı gösterdiği görülmektedir. Karışıklık matrisinde, 367 kişinin diyabetik retinopati olmadığı doğru şekilde tespit edilmiş, 374 kişinin diyabetik retinopati olduğu doğru şekilde tespit edilmiş ve teşhis konmuştur. Ancak 237 kişiye diyabetik retinopatiye konmadığı yönünde, 173 kişiye de diyabetik retinopati değilken diyabetik retinopati olduğu yönünde yanlış teşhis konmuştur. Yanlış teşhis sayısının yüksek olmasının Decision Tree algoritmasının başarı oranının düşmesine yol açtığı söylenebilir.

Z. Khairudin, N.A.A. Razak, H.A.A. Rahman, N. Kamarudin ve N.A.B.A. Aziz[9], çalışmalarında Decision Tree modelini Gini İndeksi yöntemiyle incelemiş ve %70,97 oranında başarı yakalamışlardır ancak Diabetic Retinopathy Debrecen veri setinde Decision Tree modelinin daha az oranda başarı gösterdiği söylenebilir.

D. K-NN

K-NN, sınıflandırma problemlerini çözmek için kullanılan klasik algoritmalarından biridir[10]. K-NN sınıflandırmasında, sorgunun sınıfı, örnek sorgunun en yakın komşularına göre elde edilir. K-NN, en yakın veriye giden deseni arar ve daha sonra bilinmeyen verilere atar [1].

Bu çalışmada kullandığımız veri setine k-NN algoritması k = 5 (Tablo13), k = 7 (Tablo14), k = 15 (Tablo15) olacak şekilde farklı k değerleri verilerek uygulanmıştır ve sonuçlar karşılaştırılmıştır.

Tablo13: WEKA K-NN Sınıflandırması Uygulamasında k = 5 İçin Sonuç

```

IB1 instance-based classifier
using 5 nearest neighbour(s) for classification

Time taken to build model: 0 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      722          62.7281 %
Kappa statistic                    0.2553
Mean absolute error                 0.4096
Root mean squared error            0.4878
Relative absolute error            82.2364 %
Root relative squared error        97.7491 %
Total Number of Instances         1151

=== Detailed Accuracy By Class ===

      TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
    0,644    0,388    0,595    0,644    0,619    0,256    0,678    0,602    0
    0,612    0,356    0,661    0,612    0,636    0,256    0,678    0,692    1
Weighted Avg.    0,627    0,371    0,630    0,627    0,628    0,256    0,678    0,650

=== Confusion Matrix ===

      a  b  <-- classified as
    348 192 |  a = 0
    237 374 |  b = 1

```

Tablo13 incelendiğinde, k = 5 değeri için k-NN algoritması 1151 örnekten 722 tanesini doğru sınıflandırarak %62.7281 oranında başarı göstermiştir. Karışıklık matrisinde, 340 kişinin diyabetik retinopati olmadığı doğru şekilde tespit edilmiş, 374 kişinin diyabetik retinopati olduğu doğru şekilde tespit edilmiştir. Ancak 237 kişiye diyabetik retinopatiye konmadığı yönünde, 192 kişiye de diyabetik retinopati değilken diyabetik retinopati olduğu yönünde yanlış teşhis konmuştur.

Tablo14: WEKA K-NN Sınıflandırması Uygulamasında k = 7 İçin Sonuç

```

IB1 instance-based classifier
using 7 nearest neighbour(s) for classification

Time taken to build model: 0 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      732          63.5969 %
Kappa statistic                    0.2733
Mean absolute error                 0.4138
Root mean squared error            0.4779
Relative absolute error            83.0774 %
Root relative squared error        95.7537 %
Total Number of Instances         1151

=== Detailed Accuracy By Class ===

      TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
    0,661    0,386    0,602    0,661    0,630    0,274    0,692    0,617    0
    0,614    0,339    0,672    0,614    0,642    0,274    0,692    0,704    1
Weighted Avg.    0,636    0,361    0,639    0,636    0,636    0,274    0,692    0,663

=== Confusion Matrix ===

      a  b  <-- classified as
    357 183 |  a = 0
    236 375 |  b = 1

```

Tablo14 incelendiğinde, k = 7 değeri için k-NN algoritması 1151 örnekten 732 tanesini doğru sınıflandırarak %63.5969 oranında başarı göstermiştir. Karışıklık matrisinde, 357 kişinin diyabetik retinopati olmadığı doğru şekilde tespit edilmiş, 375 kişinin diyabetik retinopati olduğu doğru şekilde

tespit edilmiştir. Ancak 236 kişiye diyabetik retinopatiye sahip olmadığı yönünde, 183 kişiye de diyabetik retinopati değilken diyabetik retinopati olduğu yönünde yanlış teşhis konmuştur.

Tablo15: WEKA K-NN Sınıflandırması Uygulamasında k = 15 İçin Sonuç

```
IB1 instance-based classifier
using 15 nearest neighbour(s) for classification

Time taken to build model: 0 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      735          63.8575 %
Kappa statistic                    0.28
Mean absolute error                0.424
Root mean squared error            0.4673
Relative absolute error            85.1145 %
Root relative squared error        93.6464 %
Total Number of Instances         1151

=== Detailed Accuracy By Class ===

          TP Rate  FP Rate  Precision  Recall   F-Measure  MDC     ROC Area  PRC Area  Class
0,681    0,399    0,601    0,681    0,639    0,282    0,704    0,646    0
0,601    0,319    0,681    0,601    0,638    0,282    0,704    0,721    1
Weighted Avg.    0,639    0,356    0,644    0,639    0,639    0,282    0,704    0,686

=== Confusion Matrix ===

  a  b  <-- classified as
368 172 |  a = 0
244 367 |  b = 1
```

Tablo15 incelendiğinde, k = 15 değeri için k-NN algoritması 1151 örnekten 735 tanesini doğru sınıflandırarak % 63.8575 oranında başarı göstermiştir. Karışıklık matrisinde, 368 kişinin diyabetik retinopati olmadığı doğru şekilde tespit edilmiş, 367 kişinin diyabetik retinopati olduğu doğru şekilde tespit edilmiştir. Ancak 244 kişiye diyabetik retinopatiye sahip olmadığı yönünde, 172 kişiye de diyabetik retinopati değilken diyabetik retinopati olduğu yönünde yanlış teşhis konmuştur.

Bu sonuçlara göre en başarılı performansı %63.8575 oranıyla k = 15 değerinin gösterdiği söylenebilir.

M. Çerkezi [8], çalışmasında k-NN yönteminin, %90 değerini aşarak diğer algoritmalarla kıyasla en iyi doğruluk oranını verdiğini belirtmiştir. Bu çalışmada ise k-NN algoritması Diabetic Retinopathy Debrecen veri setinde M. Çerkezi [8]'nin çalışmasına oranla daha düşük bir performans göstermiştir.

E. Artificial Neural Networks

Yapay sinir ağları (ANN), insan beyninin özelliklerinden olan öğrenme yolu ile yeni bilgiler türetebilme, yeni bilgiler oluşturabilme ve keşfedebilme gibi yetenekleri herhangi bir yardım almadan otomatik olarak gerçekleştirmek amacı ile geliştirilen bilgisayar sistemleridir[8]. Çok katmanlı bir sinir ağıdır; burada ilk katman giriş katmanı, son katman çıkış katmanıdır ve diğer katmanlar gizli katmanlar olarak bilinir. Her katmanda yapay nöronlar olarak bilinen birimler bulunur ve birimleri etkinleştirmek için aktivasyon fonksiyonları kullanılır[11].

Bu çalışmada WEKA aracılığıyla kullandığımız veri setine ANN algoritması farklı hidden layers ve learning rate değerleri verilerek uygulanmıştır ve sonuçlar karşılaştırılmıştır.

Tablo16 'da hidden layers = 5, learning rate = 1.0 değerleri verilmiştir ve sonuçlar incelenmiştir.

Tablo16: WEKA ANN Sınıflandırması Uygulamasında HiddenLayers = 5 , Learning Rate = 1.0 İçin Sonuç

```
Time taken to build model: 1.11 seconds

=== Stratified cross-validation ===
=== Summary ===


Correctly Classified Instances      806          70.0261 %
Kappa statistic                    0.3975
Mean absolute error                0.3503
Root mean squared error            0.4457
Relative absolute error            70.3227 %
Root relative squared error        89.3119 %
Total Number of Instances         1151

=== Detailed Accuracy By Class ===

          TP Rate  FP Rate  Precision  Recall   F-Measure  MDC     ROC Area  PRC Area  Class
0,670    0,273    0,684    0,670    0,677    0,398    0,774    0,686    0
0,727    0,330    0,714    0,727    0,720    0,398    0,774    0,830    1
Weighted Avg.    0,700    0,303    0,700    0,700    0,700    0,398    0,774    0,762

=== Confusion Matrix ===

  a  b  <-- classified as
362 178 |  a = 0
167 444 |  b = 1
```



Tablo 16 incelendiğinde, ANN algoritması mevcut veri setinde HiddenLayers = 5 , Learning Rate = 1.0 değerleri için 1151 örnekten 806 tanesini doğru sınıflandırarak %70.0261 oranında başarı göstermiştir.

Tablo17 'de hidden layers = 10, learning rate = 0.3 değerleri verilmiştir ve sonuçlar incelenmiştir.

Tablo17: WEKA ANN Sınıflandırması Uygulamasında HiddenLayers = 10 , Learning Rate = 0.3 İçin Sonuç

```
Time taken to build model: 1.95 seconds

=== Stratified cross-validation ===
=== Summary ===


Correctly Classified Instances      829          72.0243 %
Kappa statistic                    0.4382
Mean absolute error                0.3298
Root mean squared error            0.4353
Relative absolute error            66.2212 %
Root relative squared error        87.2215 %
Total Number of Instances         1151

=== Detailed Accuracy By Class ===

          TP Rate  FP Rate  Precision  Recall   F-Measure  MDC     ROC Area  PRC Area  Class
0,700    0,262    0,703    0,700    0,701    0,438    0,797    0,736    0
0,738    0,300    0,736    0,738    0,737    0,438    0,797    0,843    1
Weighted Avg.    0,720    0,282    0,720    0,720    0,720    0,438    0,797    0,793

=== Confusion Matrix ===

  a  b  <-- classified as
378 162 |  a = 0
160 451 |  b = 1
```



Tablo 17 incelendiğinde, ANN algoritması mevcut veri setinde HiddenLayers = 10 , Learning Rate = 0.3 değerleri için 1151 örnekten 829 tanesini doğru sınıflandırarak %72.0243 oranında başarı göstermiştir.

Tablo18 'de hidden layers = 10, learning rate = 1.0 değerleri verilmiştir ve sonuçlar incelenmiştir.

Tablo18: WEKA ANN Sınıflandırması Uygulamasında HiddenLayers = 10 , Learning Rate = 1.0 İçin Sonuç

```
Time taken to build model: 2.29 seconds

=== Stratified cross-validation ===
=== Summary ===


Correctly Classified Instances      783          68.0278 %
Kappa statistic                    0.3578
Mean absolute error                0.347
Root mean squared error            0.4648
Relative absolute error            65.6742 %
Root relative squared error        93.1345 %
Total Number of Instances         1151

=== Detailed Accuracy By Class ===

          TP Rate  FP Rate  Precision  Recall   F-Measure  MDC     ROC Area  PRC Area  Class
0,656    0,298    0,660    0,656    0,658    0,358    0,762    0,690    0
0,702    0,344    0,698    0,702    0,700    0,358    0,762    0,811    1
Weighted Avg.    0,680    0,323    0,680    0,680    0,680    0,358    0,762    0,754

=== Confusion Matrix ===

  a  b  <-- classified as
354 186 |  a = 0
182 429 |  b = 1
```



Tablo 18 incelendiğinde, ANN algoritması mevcut veri setine HiddenLayers = 10, Learning Rate = 1.0 değerleri için 1151 örnekten 783 tanesini doğru sınıflandırarak % 68.0278 oranında başarı göstermiştir.

Buna göre, ANN algoritmasının, HiddenLayers = 10, Learning Rate = 0.3 değerleri için %72.0243 oranıyla en başarılı performansı gösterdiği söylenebilir.

Z. Khairudin, N.A.A. Razak, H.A.A. Rahman, N. Kamarudin ve N.A.B.A. Aziz[9], çalışmalarında inceledikleri veri setine ANN algoritmasını uygulamış ve %64.55 doğruluk oranı elde etmişlerdir. Bu çalışmada ise ANN algoritması Diabetic Retinopathy Debrecen veri setinde %72.0243 doğruluk oranı göstererek Z. Khairudin, N.A.A. Razak, H.A.A. Rahman, N. Kamarudin ve N.A.B.A. Aziz[9]' in çalışmalarına oranla daha yüksek bir performans göstermiştir.

V. SONUÇLAR VE ÖNERİLER

Bu bölümde, Diabetic Retinopathy Debrecen veri setine uygulanan Lojistik Regresyon, Naïve Bayes, Decision Tree, k-NN, Yapay Sinir Ağları (ANN) sınıflandırma algoritmaları [4. Bölüm] sonucunda elde edilen bulgular karşılaştırılmıştır. Mevcut veri seti için en iyi performansı gösteren sınıflandırma algoritması belirtilmiştir. Diyabetik retinopatinin veri madenciliği teknikleriyle teşhisi, uygun görülen işletme, hükümet ve kuruluşlarla ilişkilendirilmiştir.

Bu çalışmada incelenen mevcut veri setine çeşitli sınıflandırma algoritmaları uygulanmış ve doğruluk oranının genelde %65 ile %70 aralığında olduğu görülmüştür. Lojistik Regresyon yöntemi %74.89 oranında, Naïve Bayes algoritması %56.8202 oranında, Decision Tree algoritması %64.3788 oranında, k-NN algoritması; k = 5 değeri için %62.7281 oranında, k = 7 değeri için %63.5969 oranında, k = 15 değeri için % 63.8575 oranında, ANN algoritması; HiddenLayers = 5, Learning Rate = 1.0 değerleri için %70.0261 oranında, HiddenLayers = 10, Learning Rate = 0.3 değerleri için %72.0243 oranında, HiddenLayers = 10, Learning Rate = 1.0 değerleri için % 68.0278 oranında başarı göstermiştir. Buna göre mevcut veri seti için incelenen algoritmalar arasında en yüksek performansı %74.89 doğruluk oranıyla Lojistik Regresyon sınıflandırma algoritmasının gösterdiği söylenebilir. Mevcut veri seti için incelenen algoritmalar arasında en düşük performansı ise %56.8202 doğruluk oranıyla Naïve Bayes algoritmasının gösterdiği görülmektedir.

Bu çalışmanın, öncelikli olarak diyabet hastaları olmak üzere toplumun büyük bir kesimini ilgilendirdiği söylenebilir. Sağlık Bakanlığı'nın geliştirmiş olduğu "Erişkin Diyabetli Bireyler İçin Eğitimci Rehberi" [12] başlıklı rehberde, tanısı ve tedavisi zamanında yapılmadığı zaman körlüğe neden olabileceği belirtilerek diyabetik retinopatide erken teşhisin öneminin üzerinde durulmuştur. Buna göre, bu çalışmanın Sağlık Bakanlığı, devlet hastaneleri ve özel hastaneler, göz klinikleri gibi sağlık kuruluşlarıyla ilişkilendirilerek, diyabetik retinopatinin erken teşhis sürecine katkı sağlaması amaçlanmaktadır.

REFERENCES

[1] S. Vadloori, Y.-P. Huang, W.-C. Wu "Comparison of Various Data Mining Classification Techniques in the Diagnosis of Diabetic Retinopathy", Acta Polytechnica Hungarica, Vol. 16, No. 9, 2019, pp.29-46

[Online]. Available: https://www.researchgate.net/profile/Spandana-Vadloori/publication/342170912_Comparison_of_Various_Data_Mining_Classification_Techniques_in_the_Diagnosis_of_Diabetic_Retinopathy/links/659e54e32468df72d3070da2/Comparison-of-Variou-Data-Mining-Classification-Techniques-in-the-Diagnosis-of-Diabetic-Retinopathy.pdf

[2] M.Z. Atwany, A.S. Sahyoun, and M. Yaqub, "Deep learning techniques for diabetic retinopathy classification: A survey," IEEE Access, vol. 10, pp. 28642-28655, 2022, DOI: 10.1109/ACCESS.2022.3157632. [Online]. Available: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=9729867>

[3] L. Guariguata, D. R. Whiting, I. Hambleton, J. Beagley, U. Linnenkamp and J. E. Shaw, "Global estimates of diabetes prevalence for 2013 and projections for 2035," Diabetes research and clinical practice, vol. 103, no. 2, pp. 137-149, 2014. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0168822713003859>

[4] N.T.A Ramaha, S.I. Al-Dujaili, "Diabetic retinopathy diagnosis using machine learning versus deep learning" European Journal of Science and Technology, no. 51, pp. 301-313, Aug. 2023, DOI: 10.31590/ejosat.1263514. [Online]. Available: <https://dergipark.org.tr/en/download/article-file/3003938>

[5] "Diabetic Retinopathy Debrecen dataset," UCI Machine Learning Repository. [Online]. Available: <https://archive.ics.uci.edu/dataset/329/diabetic+retinopathy+debrecen> Accessed: Dec. 1, 2025.

[6] O.F. Gurcan, O.F. Beyca, O. Dogan, "A comprehensive study of machine learning methods on diabetic retinopathy classification" Atlantis Press, vol. 14(2), 2021, pp.1132-1141, DOI: <https://doi.org/10.2991/ijcis.d.210316.001> [Online]. Available: https://www.academia.edu/98364551/A_Comprehensive_Study_of_Machine_Learning_Methods_on_Diabetic_Retinopathy_Classification

[7] R. Priya and P. Aruna, "Diagnosis of diabetic retinopathy using machine learning techniques," Ictact Journal On Soft Computing, July 2013, vol. 03, DOI: 10.21917/ijsc.2013.0083 [Online]. Available: https://ictactjournals.in/paper/IJSC_V3_I4_Paper_1_563-575.pdf

[8] M. Çerkezi, "Veri madenciliği yöntemlerini kullanarak diyabetik retinopati hastalığının teşhisi," Yüksek Lisans Tezi, Sakarya Üniversitesi (Turkey), 2013. ProQuest Dissertations & Theses, 2013. 29177377. [Online]. Available: <https://www.proquest.com/docview/2700776437?pq-origsite=gscholar&fromopenview=true&sourcecetype=Dissertations%20&%20Theses>

[9] Z. Khairudin, N. A. A. Razak, H. A. A. Rahman, N. Kamarudin and N.A.B.A. Aziz, "Prediction of diabetic retinopathy among type ii diabetic patients using data mining techniques," Malaysian Journal of Computing, 5 (2): 572-586, 2020 [Online]. Available: <https://ir.uitm.edu.my/id/eprint/48124/1/48124.pdf>

[10] G.T. Reddy, S.B. Bhattacharya, S.R. Siva, C.L. Chowdhary, P.K.Reddy M., S. Hakak, R. Kaluri, "An Ensemble based Machine Learning model for Diabetic Retinopathy Classification," International Conference on Emerging Trends in Information Technology and Engineering (ic-ETITE), 2020, pp. 1-6 [Online]. Available: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=9077904>

[11] K. Bhatia, S. Arora, R. Tomar, "Diagnosis of Diabetic Retinopathy Using Machine Learning Classification Algorithm," International Conference on Next Generation Computing Technologies (NGCT-2016), Dehradun, India 14-16 October 2016, pp.347 – 351 [Online]. Available: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=7877439>

[12] T:C Sağlık Bakanlığı, "Erişkin Diyabetli Bireyler İçin Eğitimci Rehberi," Türkiye Halk Sağlığı Kurumu, Ankara, 2015, ISBN: 978-975-590-498-6, pp.69-70 [Online]. Available: <https://hsgm.saglik.gov.tr/depo/birimler/saglikli-beslenme-ve-hareketli-hayat-db/Dokumanlar/Rehberler/Diyabetli-Bireyler-Icin-Egitimci-Rehberi.pdf>